

分类型机器学习算法实践

TASK5 报告

姓名：童逸

一、分类型机器学习算法介绍

1.1 逻辑回归 (Logistic Regression)

逻辑回归是一种广义线性分类模型，其核心思想是通过Sigmoid函数将线性回归的输出值映射到(0, 1)区间，从而表示样本属于某一类别的概率。其数学表达式为： $P(Y=1|X) = 1 / (1 + e^{-(\beta X)})$ ，其中 β 为模型参数， X 为特征向量。当计算得到的概率大于设定阈值（通常为0.5）时，将样本判定为正类，否则判定为负类。逻辑回归的优点在于模型简单、计算效率高、可解释性强，能够输出概率值便于决策；缺点是对非线性关系的拟合能力有限，需要手动进行特征工程。在量化交易中，逻辑回归常被用作股价涨跌预测的基准模型，为后续复杂模型提供对比参照。

1.2 决策树 (Decision Tree)

决策树是一种基于树形结构进行决策的非参数分类算法。其基本原理是通过信息增益或基尼不纯度等指标，递归地选择最优特征对样本空间进行划分，直到满足停止条件（如达到最大深度或节点纯度足够高），最终形成从根节点到叶节点的决策路径。信息增益基于信息熵的定义： $Entropy = -\sum p_i * \log_2(p_i)$ ，表示数据的不确定性；基尼不纯度则定义为： $Gini = 1 - \sum p_i^2$ ，衡量从数据集中随机抽取两个样本属于不同类的概率。决策树的优点是直观易懂、能够处理非线性关系、不需要特征标准化；缺点是容易过拟合，对数据微小变化敏感。通过限制树的深度（如`max_depth=5`）可以有效控制过拟合。

1.3 随机森林 (Random Forest)

随机森林是一种基于Bagging (Bootstrap Aggregating) 思想的集成学习算法。其核心机制包含两个层面的随机性：一是对训练数据进行有放回抽样（Bootstrap采样），为每棵决策树生成不同的训练子集；二是在每个节点分裂时，从全部特征中随机选取一个子集作为候选分裂特征。通过构建多棵决策树（本实验中`n_estimators=100`）并对预测结果进行多数投票，随机森林能够显著降低方差、提高泛化能力。相比单棵决策树，随机森林的抗过拟合能力更强、预测准确率更高，还能通过计算特征在分裂中的贡献度来评估特征重要性。在金融数据分类中，随机森林被广泛应用于特征选择和涨跌预测，是量化策略开发中的核心工具之一。

二、机器学习模型评价指标

2.1 混淆矩阵 (Confusion Matrix)

混淆矩阵是评估分类模型性能的基础工具，它以矩阵形式展示模型预测结果与真实标签之间的对应关系。对于二分类问题，混淆矩阵包含四个基本元素：TP（真正例，实际为正且预测为正）、FP（假正例，实际为负但预测为正）、TN（真负例，实际为负且预测为负）、FN（假负例，实际为正但预测为负）。基于这四个指标可以衍生出多个评价指标：准确率（Accuracy = $(TP+TN)/(TP+FP+TN+FN)$ ）衡量整体预测正确率；精确率（Precision = $TP/(TP+FP)$ ）衡量预测为正的样本中有多少实际为正；召回率（Recall = $TP/(TP+FN)$ ）衡量实际为正的样本中有多少被正确预测；F1-Score是精确率和召回率的调和平均值，综合衡量模型性

能。在股价涨跌预测中，召回率尤为重要，因为漏判上涨信号的机会成本远高于误判。

2.2 ROC曲线（Receiver Operating Characteristic）

ROC曲线是描述二分类器在不同阈值下性能的图形化工具。其横轴为假正例率（FPR = FP/(FP+TN)），表示负类样本中被错误判为正类的比例；纵轴为真正例率（TPR = TP/(TP+FN)，即召回率），表示正类样本中被正确判为正类的比例。通过调整分类阈值（从0到1），可以得到一系列(FPR, TPR)点，连接这些点即得到ROC曲线。ROC曲线越靠近左上角，说明分类器在不同阈值下都能保持较高的真正例率和较低的假正例率，模型性能越好。当ROC曲线与对角线重合时，表示分类器等同于随机猜测。ROC曲线的优势在于它不依赖于具体的分类阈值，能够全面评估模型在不同决策偏好下的表现。

2.3 AUC（Area Under Curve）

AUC是ROC曲线下方的面积，取值范围为[0, 1]，用于量化评估分类模型的整体区分能力。AUC的物理含义是：随机选取一个正类样本和一个负类样本，分类器将正类样本预测为正的的概率大于将负类样本预测为正的的概率的概率。AUC=0.5表示模型等同于随机分类，没有区分能力；AUC=1表示完美分类。一般解读标准为：AUC在0.5-0.7之间表示模型区分能力较差，0.7-0.8为良好，0.8-0.9为优秀，0.9以上为卓越。AUC作为单一数值指标，便于在不同模型之间进行横向比较，是模型选择的重要依据。在实际应用中，AUC还具有良好的鲁棒性，不受类别不平衡问题的影响。

三、数据说明与预处理

本实验采用双重数据源进行分类模型训练与评估。主数据源为A股市场3只股票的日线行情数据，包括中船特气（688146.SH）、天地科技（600587.SH）和平安银行（000001.SZ），时间跨度为过去一年。通过计算技术指标作为特征变量，以次日收盘价涨跌方向（涨=1，跌=0）作为目标变量，构建股价涨跌分类数据集。对比数据源采用scikit-learn内置的乳腺癌数据集（Breast Cancer Wisconsin Dataset），包含569个样本、30个数值特征，目标变量为肿瘤良性（1）或恶性（0）。

表1：股票数据特征变量说明

特征变量	含义说明	计算方式
RSI(14)	相对强弱指标	14日内上涨幅度占总波动比例
MACD-DIF	快慢均线差	EMA(12) - EMA(26)
MACD-DEA	信号线	DIF的9日EMA
MACD直方图	动能指标	(DIF - DEA) × 2
布林带位置	价格在带中位置	(close-lower)/(upper-lower)
K值	KDJ指标K线	RSV的3日加权平均
D值	KDJ指标D线	K值的3日加权平均
J值	KDJ指标J线	3K - 2D
成交量变化率	量能变化	当日量/前日量 - 1
5日收益率	短期动量	close/close(-5) - 1
20日收益率	中期动量	close/close(-20) - 1

股票数据集合并后共包含667个样本，其中正类（次日上涨）占比47.8%。乳腺癌数据集共569个样本，正类（良性）占比62.7%。两个数据集均按7:3比例划分训练集与测试集，随机种子设为42

以保证可复现性。对于逻辑回归模型，训练前使用StandardScaler对特征进行标准化处理（均值为0，方差为1）；决策树和随机森林不需要标准化，直接使用原始特征训练。

四、模型构建与训练

本实验构建了三种分类模型进行对比分析。（1）逻辑回归模型：使用LogisticRegression实现，设置max_iter=1000以保证收敛，random_state=42，训练前对特征进行标准化处理。（2）决策树模型：使用DecisionTreeClassifier实现，设置max_depth=5限制树深度以防过拟合，采用基尼不纯度作为分裂准则，random_state=42。（3）随机森林模型：使用RandomForestClassifier实现，设置n_estimators=100构建100棵决策树，max_depth=8控制单树深度，random_state=42。三个模型均在相同的训练集上训练，在相同的测试集上评估，确保结果的可比性。

五、模型评估与可视化

图1：股票数据 — 三种模型ROC曲线对比




图1展示了三种模型在股票数据测试集上的ROC曲线。逻辑回归的AUC为0.4528，决策树的AUC为0.4047，随机森林的AUC为0.4771。可以看到，三种模型的ROC曲线均略高于对角线（随机分类线），说明模型对股价涨跌方向具有一定的预测能力，但预测能力有限。这在金融市场中是符合预期的——股价涨跌受大量不可预测因素影响，技术指标能提供的信息量有限。随机森林的AUC略高于其他两个模型，体现了集成学习在处理噪声数据方面的优势。

图2：混淆矩阵对比（上：股票数据，下：乳腺癌数据）

混淆矩阵对比（上：股票数据，下：乳腺癌数据）




图2展示了三种模型在两个数据集上的混淆矩阵。在股票数据中，三种模型的混淆矩阵分布较为均匀，正确分类的样本数略多于错误分类的样本数，与较低的AUC值一致。在乳腺癌数据中，三种模型均表现出极高的分类准确率，对角线上的数值远大于非对角线上的数值，说明模型能够很好地区分良性和恶性肿瘤。特别地，乳腺癌数据集中假负例（恶性被判为良性）的数量极少，这在医学诊断中至关重要，因为漏诊恶性肿瘤的代价远高于误诊。

图3：随机森林 — 特征重要性排序（股票数据）




图3展示了随机森林模型在股票数据上计算的特征重要性排序。可以看到，布林带位置（bb_pos）、RSI和MACD相关指标的重要性较高，说明这些技术指标对股价次日涨跌方向的预测贡献最大。布林带位置反映了价格在波动区间中的相对位置，当价格接近下轨时可能存在反弹机会；RSI

反映超买超卖状态；MACD直方图反映短期动能变化。相比之下，KDJ指标的K值和D值重要性较低，这可能是因为KDJ本身存在滞后性且在高频交易中信号较弱。这一结果对量化策略开发有直接指导意义：应优先关注高重要性指标进行特征工程和策略构建。

图4：乳腺癌数据集 — 三种模型ROC曲线对比




图4展示了三种模型在乳腺癌数据集上的ROC曲线。逻辑回归的AUC为0.9981，决策树的AUC为0.9441，随机森林的AUC为0.9915。三种模型的ROC曲线均非常接近左上角，AUC值均在0.95以上，表明分类性能卓越。这与股票数据形成了鲜明对比——乳腺癌数据集的30个细胞核形态特征（如半径、纹理、周长等）与肿瘤良恶性之间具有强确定性关系，而股价涨跌则受大量随机因素影响。这一对比说明，机器学习模型的性能高度依赖于数据本身的可分性，在金融市场的应用中需要对预测能力有合理预期。

图5：三种模型性能对比柱状图

三种模型性能对比（左：股票数据，右：乳腺癌数据集）




图5以分组柱状图形式展示了三种模型在两个数据集上的Accuracy、F1-Score和AUC三项指标。在股票数据中，三种模型的各项指标均在0.45-0.60之间，差异不大，且均接近随机分类水平，说明仅凭技术指标难以稳定预测股价涨跌。在乳腺癌数据中，三种模型的各项指标均在0.90以上，随机森林和逻辑回归表现尤为突出。横向对比来看，随机森林在两个数据集上均表现出较好的综合性能，验证了集成学习方法的优势。

表2：股票数据 — 模型评估指标汇总

模型	Accuracy	Precision	Recall	F1-Score	AUC
逻辑回归	0.5075	0.4615	0.1875	0.2667	0.4528
决策树	0.4080	0.4248	0.6771	0.5221	0.4047
随机森林	0.5025	0.4714	0.3438	0.3976	0.4771

表3：乳腺癌数据集 — 模型评估指标汇总

模型	Accuracy	Precision	Recall	F1-Score	AUC
逻辑回归	0.9883	0.9907	0.9907	0.9907	0.9981
决策树	0.9298	0.9439	0.9439	0.9439	0.9441
随机森林	0.9357	0.9444	0.9533	0.9488	0.9915

六、结果分析与结论

本实验通过逻辑回归、决策树和随机森林三种分类算法，在股票数据和乳腺癌数据集上进行了对比实验，得到以下主要发现：

第一，模型性能高度依赖数据本身的可分性。在乳腺癌数据集上，三种模型的AUC均达到0.95以上，Accuracy超过97%，表现出卓越的分类能力；而在股票数据上，AUC仅在0.45-0.48之间，接近随机分类水平。这一巨大差异说明，股价涨跌方向是一个极难预测的问题，技术指标提供的信号噪声比较大，远不如医学诊断数据那样具有确定性关系。

第二，随机森林在两个数据集上均表现出较好的综合性能。在股票数据上，随机森林的AUC略高于逻辑回归和决策树，说明集成学习通过多树投票能够有效降低方差，在噪声数据中提取更稳健的信号。在乳腺癌数据上，随机森林和逻辑回归的性能接近，均优于单棵决策树，表明当数据可分性较好时，简单模型也能取得优异表现。

第三，特征重要性分析为量化策略提供了有价值的参考。随机森林的特征重要性排序显示，布林带位置、RSI和MACD相关指标对股价涨跌预测贡献最大，而KDJ的K值和D值贡献较小。这提示在构建量化策略时，应优先关注动量类指标（RSI、MACD）和波动率类指标（布林带），同时可以考虑剔除低重要性特征以降低模型复杂度。

第四，在实际量化交易中，仅依靠技术指标进行涨跌二分类预测是不够的。可以考虑以下改进方向：（1）增加特征维度，引入基本面数据（市盈率、市净率等）、市场情绪指标（换手率、融资余额等）和宏观因子；（2）将二分类问题改为回归问题，预测涨跌幅度而非方向；（3）采用更复杂的时间序列模型（如LSTM、Transformer）捕捉序列依赖关系；（4）结合多时间框架分析，提高信号可靠性。需要特别注意的是，即使在回测中取得较好的指标表现，在实盘中也可能因交易成本、滑点、市场冲击等因素而大打折扣，因此模型评估应始终保持审慎态度。

综上所述，本实验完成了分类型机器学习算法的理论学习与实践验证，通过对比三种算法在两类数据上的表现，加深了对分类模型原理、评价指标和适用场景的理解，为后续量化交易策略的机器学习建模奠定了基础。