

量化交易策略开发与机器学习应用

学习成果综合报告

——基于七个阶段实践的系统总结

作者：童逸

日期：2026年7月

课程：AI大模型辅助的金融交易策略

目 录

摘 要.....	1
一、量化交易核心概念.....	2
（一）量化交易的基本概念.....	2
（二）量化交易的核心价值.....	2
二、量化交易策略综合分析.....	3
（一）数据获取与技术分析基础.....	3
（二）双均线策略.....	4
（三）海龟交易策略.....	5
（四）策略对比与多策略系统构建.....	6
三、机器学习在量化交易中的应用总结.....	8
（一）分类模型与评估指标.....	8
（二）机器学习交易策略与回测.....	9
（三）平台实现与实盘模拟.....	10
（四）优势、局限与未来趋势.....	11
四、结论与展望.....	12
附录：改进建议.....	13

摘要

本报告系统总结了量化交易策略开发与机器学习应用的学习成果。研究以中船特气、天地科技、平安银行三只股票的日线数据为基础，依次完成了数据获取、技术指标计算、双均线策略、海龟交易策略、分类模型构建、机器学习交易策略以及平台实盘模拟七个阶段的实践。在传统策略方面，双均线策略在中船特气上实现了980.26%的年化收益，海龟策略通过唐奇安通道和ATR止损将最大回撤控制在17.41%。在机器学习方面，以16个技术因子为自变量、未来5日涨跌方向为应变量，构建了逻辑回归、决策树和随机森林三种分类模型，并在聚宽平台上实现了滚动训练与动态调仓的实盘模拟策略，年化收益率达61.49%，夏普比率为2.27，最大回撤为11.42%。研究表明，机器学习策略在控制回撤方面具有显著优势，但在短期股价预测精度上仍受市场随机性的制约，多策略组合是降低风险、提升稳健性的有效途径。

一、量化交易核心概念

（一）量化交易的基本概念

量化交易是指利用数学模型、统计方法和计算机程序，对金融市场数据进行系统分析，自动生成交易信号并执行交易的投资方法。其核心在于将投资逻辑转化为可量化、可回测、可复现的规则体系，以数据和算法替代主观判断，从而提升决策的客观性和执行效率。一个完整的量化交易系统通常包括数据获取、因子构建、信号生成、风险管理和执行交易五个环节，各环节紧密衔接、相互支撑。

（二）量化交易的核心价值

第一，客观性。量化交易通过预设规则消除情绪干扰，避免人在恐慌或贪婪时的非理性决策。在本课程的实践中，无论是双均线策略的金叉死叉信号，还是机器学习模型的概率输出，均严格依据模型计算结果执行，不掺杂主观臆断，保证了交易纪律的一致性。

第二，可回测性。量化策略在投入实盘前，可在历史数据上进行充分回测，评估其在不同市场环境下的表现。本报告中，双均线策略测试了5组参数，海龟策略测试了3组通道周期，机器学习策略进行了9组参数调优，通过系统比较筛选出最优配置，为实盘部署提供了数据支撑。

第三，可扩展性。量化系统可同时监控和交易大量标的，实现规模化的投资管理。本报告中的策略均在3只不同特征的股票上进行了测试，涵盖科创板、主板和金融板块，验证了策略的跨品种适用性。

第四，系统性风险管理。量化交易通过最大回撤、夏普比率、风险价值等指标对策略风险进行量化度量，并结合止损规则、仓位管理实现系统化的风险控制。海龟策略的ATR止损和机器学习策略的动态仓位管理均体现了这一价值。

二、量化交易策略综合分析

（一）数据获取与技术分析基础

本研究的全部策略均建立在可靠的行情数据基础上。通过Tushare金融数据接口，获取了中船特气（688146）、天地科技（600587）和平安银行（000001）三只股票过去一年的日线行情数据，包括开盘价、收盘价、最高价、最低价和成交量。在数据质量方面，对缺失值和异常值进行了诊断清洗，确保后续分析和建模的准确性。

在技术分析层面，计算了相对强弱指标（RSI）、平滑异同移动平均线（MACD）、布林带和随机指标（KDJ）四类经典技术指标。这些指标从动量、趋势、波动率和超买超卖四个维度刻画了价格运动特征，为后续的策略开发和机器学习特征工程奠定了基础。其中RSI用于衡量价格变化的力度，MACD捕捉趋势的转折，布林带反映波动率的动态变化，KDJ则识别短期的超买超卖区域。

（二）双均线策略

双均线策略是最经典的趋势跟踪策略之一。其核心逻辑是：当短期均线上穿长期均线时产生金叉买入信号，当短期均线下穿长期均线时产生死叉卖出信号。本研究在中船特气、天地科技和平安银行三只股票上，测试了短均线周期为5日和10日、长均线周期为15日、20日和30日的5组参数组合，共15种配置。回测采用前一日信号、当日收盘价执行的机制，评估了累计回报、年化收益、夏普比率、最大回撤和胜率等指标。

表1 双均线策略参数对比结果（中船特气）

短均线	长均线	年化收益(%)	夏普比率	最大回撤(%)	交易次数	胜率(%)
5	15	980.26	13.11	-27.96	7	42.86
5	20	735.86	10.13	-32.82	7	28.57
10	20	714.26	9.86	-30.43	6	33.33
5	30	742.46	10.13	-33.23	6	33.33
10	30	723.95	9.91	-28.51	6	33.33

从表1可以看出，5日/15日参数组合表现最优，年化收益率达到980.26%，夏普比率为13.11，但最大回撤也高达27.96%。这说明双均线策略在趋势明朗的个股上收益突出，但回撤控制能力有限。在天地科技和平安银行上，策略表现明显弱于中船特气，体现了该策略对标的趋势性的高度依赖。（详见附录建议1）

（三）海龟交易策略

海龟交易策略由理查德·丹尼斯在20世纪80年代提出，其核心思想是利用唐奇安通道捕捉趋势突破信号，并通过平均真实波幅（ATR）进行动态止损和仓位管理。当价格突破过去N日最高价时买入，跌破过去M日最低价时卖出，同时以ATR的倍数设定止损价位，控制单笔交易的最大亏损。本研究测试了10日/5日、20日/10日和55日/20日三组通道参数，覆盖短线、中线和长线三种趋势跟踪风格。

表2 海龟策略参数对比结果（部分）

股票	通道参数	策略收益(%)	买入持有(%)	夏普比率	最大回撤(%)	胜率(%)
中船特气	10日/5日	787.60	1179.83	3.58	-17.41	50.00
中船特气	20日/10日	543.94	1179.83	3.11	-34.52	40.00
中船特气	55日/20日	543.10	1179.83	3.36	-13.91	0.00
天地科技	10日/5日	2.63	-23.38	0.03	-9.88	66.67
平安银行	20日/10日	-8.29	-13.01	-1.77	-8.29	25.00

从表2可以看出，海龟策略在趋势性较强的中船特气上表现优异，10日/5日参数组合实现了787.60%的累计收益和50%的胜率。更值得关注的是，55日/20日长周期组合虽然收益略低，但将最大回撤从19.89%（买入持有）降至13.91%，体现了ATR止损在风控方面的价值。在天地科技上，海龟策略成功规避了23.38%的下跌，实现2.63%的正收益，说明该策略在震荡下行市场中具有防御能力。（详见附录建议2）

（四）策略对比与多策略系统构建

为直观比较各类策略的表现差异，将双均线策略、海龟策略以及后续的机器学习策略在中船特气上的关键指标进行了汇总对比。




图1 各策略年化收益率对比（中船特气）

图1显示，双均线策略在中船特气上的年化收益率最高（980.26%），海龟策略次之（787.60%），机器学习随机森林策略为490.95%。但需要注意的是，收益率的排名与回撤幅度密切相关——高收益往往伴随高风险，仅看收益率无法全面评估策略优劣。




图2 各策略最大回撤对比（中船特气）

图2揭示了风险控制方面的显著差异。机器学习策略的最大回撤仅为9.68%，远低于双均线策略的27.96%和海龟策略的17.41%。这表明机器学习模型通过动态仓位调整，在市场剧烈波动时能够主动降低暴露，有效控制下行风险。




图3 各策略夏普比率对比（中船特气）

图3从风险调整收益的角度进行比较。双均线策略的夏普比率最高（13.11），但这主要受益于中船特气在该期间的强劲趋势。机器学习策略的夏普比率为3.33，虽然绝对值低于传统策略，但考虑到其更低的回撤和更稳健的净值曲线，在风险收益平衡上具有独特优势。




图4 各策略风险收益散点图

图4以散点图形式综合展示了各策略的风险收益特征。位于左上方的策略具有“低风险、高收益”的理想特征。平台组合策略（年化波动率21.20%、年化收益61.49%）在风险控制方面表现突出，虽然收益率不及趋势策略，但单位风险获得的回报更为稳定。这为构建多策略系统提供了思路：通过组合不同风格、不同周期的策略，可以在收益和风险之间取得更好的平衡。（详见附录建议3）

综合来看，双均线策略适合趋势明确的牛市环境，海龟策略在波动较大的市场中通过止损机制体现防御价值，机器学习策略则在回撤控制上优势明显。三者收益来源和风险特征上具有互

补性，构建多策略组合系统——将趋势跟踪、通道突破和机器学习预测按一定权重配置——有望在不同市场环境下实现更稳健的整体表现。

三、机器学习在量化交易中的应用总结

（一）分类模型与评估指标

机器学习在量化交易中的第一步是解决分类问题——预测未来价格涨跌方向。本研究构建了逻辑回归、决策树和随机森林三种分类模型，以RSI、MACD、布林带、KDJ等11个技术指标为自变量，以次日涨跌方向（涨为1，跌为0）为应变量。同时在scikit-learn乳腺癌数据集上进行了对比验证。数据按7:3划分为训练集和测试集，采用分层抽样保证类别平衡。

表3 机器学习分类模型评估结果

数据集	模型	准确率	精确率	召回率	F1值	AUC
股票数据	逻辑回归	0.5075	0.4615	0.1875	0.2667	0.4528
股票数据	决策树	0.4080	0.4248	0.6771	0.5221	0.4047
股票数据	随机森林	0.5025	0.4714	0.3438	0.3976	0.4771
乳腺癌数据	逻辑回归	0.9883	0.9907	0.9907	0.9907	0.9981
乳腺癌数据	决策树	0.9298	0.9439	0.9439	0.9439	0.9441
乳腺癌数据	随机森林	0.9357	0.9444	0.9533	0.9488	0.9915

表3的结果揭示了一个重要现象：在股票数据上，三种模型的AUC值均接近0.5（随机分类水平），说明仅凭技术指标难以有效预测次日涨跌方向。而在乳腺癌数据集上，逻辑回归的AUC高达0.9981，表明模型本身没有问题，问题在于金融市场数据的信噪比极低。这一发现对后续策略设计具有重要指导意义：不应过度追求分类精度，而应关注如何利用模型概率输出构建有正期望的交易策略。




图5 机器学习分类模型AUC对比

图5直观展示了两数据集上AUC的巨大差异。股票数据的AUC集中在0.40至0.48区间，低于随机分类线0.5，反映出短期股价运动的高度随机性。乳腺癌数据的AUC均在0.94以上，验证了模型在结构化数据上的强大能力。（详见附录建议4）

（二）机器学习交易策略与回测

在分类模型的基础上，进一步将预测结果转化为可执行的交易策略。策略逻辑为：当模型预测上涨时全仓持有，预测下跌时空仓观望。自变量扩展为16个技术因子，涵盖动量、趋势、波动率和量能四大类。应变量调整为未来5日涨跌方向，以降低日度噪声的影响。采用时间序列7:3划分训练集和测试集，避免前视偏差。回测评估了累计净值、季度收益率、夏普比率、最大回撤和胜率等指标。

表4 机器学习交易策略回测结果

股票	模型	年化收益 (%)	夏普比率	最大回撤 (%)	胜率 (%)	交易次数
中船特气	逻辑回归	18.42	1.12	-3.34	57.14	3
中船特气	决策树	184.65	2.64	-2.92	64.29	5
中船特气	随机森林	490.95	3.33	-9.68	62.86	22
平安银行	随机森林	-27.66	-4.61	-9.56	20.00	13
三股组合	随机森林	39.16	1.35	-7.91	—	—

表4显示，随机森林在中船特气上取得了490.95%的年化收益和3.33的夏普比率，同时将最大回撤控制在9.68%，显著优于买入持有的13.66%。但在平安银行上策略表现不佳，年化收益为-27.66%，说明模型在缺乏趋势的市场中容易产生错误信号。三股等权组合策略的年化收益为39.16%，夏普比率为1.35，最大回撤仅7.91%，体现了分散化投资对降低非系统性风险的作用。（详见附录建议5）

图6 机器学习策略累计净值对比（中船特气）




图6 机器学习策略累计净值对比（中船特气）

图6对比了三种模型在中船特气上的累计净值表现。随机森林的累计净值最高（5.91），远超逻辑回归（0.82）和决策树（0.21）。但与买入持有（40.91）相比仍有较大差距，这是因为模型在部分上涨时段选择了空仓，错过了部分收益。这一“取舍”正是机器学习策略的核心价值——通过放弃部分上行空间来换取下行保护。

（三）平台实现与实盘模拟

在掌握策略原理后，进一步在聚宽（JoinQuant）量化平台上进行了实盘模拟。平台策略基于随机森林模型，采用月度训练、周度调仓的框架，设置了8%止损线、35%最大仓位和55%置信度阈值三重风控机制。为适应平台的事件驱动架构，将策略逻辑封装为初始化函数和数据处理函数，利用平台的行情接口和订单接口实现自动化交易。同时进行了9组参数调优实验，测试了不同的树数量（50、100、200）和最大深度（3、5、10）组合。

表5 聚宽平台策略回测结果

指标	机器学习组合策略	等权买入持有
累计收益率(%)	57.54	123.09
年化收益率(%)	61.49	133.04
夏普比率	2.27	3.01
最大回撤(%)	-11.42	-13.18
年化波动率(%)	21.20	28.86
日胜率(%)	52.00	57.56
Beta	0.54	1.00

表5的回测结果表明，机器学习组合策略虽然在绝对收益上低于买入持有（年化61.49%对133.04%），但在风险控制方面表现突出：年化波动率从28.86%降至21.20%，最大回撤从13.18%改善至11.42%，Beta值仅为0.54，说明策略与市场基准的相关性较低，具备一定的市场中性特征。风险价值分析显示，95%置信度下的日最大损失为0.73%，99%置信度下为1.35%，均在可接受范围内。（详见附录建议6）

（四）优势、局限与未来趋势

优势方面，机器学习策略具有非线性建模能力，能够捕捉技术指标之间的复杂交互关系；通过滚动训练实现模型自适应，适应市场环境的变化；动态仓位管理使策略在风险控制上优于传统的全仓策略。

局限方面，金融数据的低信噪比使得分类精度难以大幅提升（AUC接近0.5）；模型容易过拟合历史数据，在样本外的泛化能力存在不确定性；技术指标因子多为价格衍生变量，信息冗余度较高；策略回测未充分考虑交易成本和滑点的影响。

未来趋势方面，深度学习模型（如长短期记忆网络和Transformer）在时序预测中展现出更强的特征提取能力；自然语言处理技术可从新闻和公告中提取文本因子，丰富信息维度；强化学习在动态仓位管理和执行优化方面具有潜力；图神经网络可建模股票间的关联关系，辅助组合构建。这些方向为量化交易的进一步发展提供了广阔空间。

四、结论与展望

（一）主要收获

通过七个阶段的系统学习和实践，本研究在以下方面取得了显著收获。在理论层面，深入理解了量化交易的核心框架——从数据获取到信号生成、从回测验证到风险管理的完整闭环。掌握了双均线策略、海龟交易策略和机器学习策略的原理与实现方法，明确了各类策略的适用条件和局限性。

在技术层面，熟练运用Python进行金融数据处理、技术指标计算、策略回测和可视化展示。掌握了scikit-learn机器学习库的使用，能够构建和评估分类模型。在聚宽平台上完成了从策略编写到实盘模拟的全流程操作，具备了量化策略开发与部署的实践能力。

在实践层面，通过多股票、多参数的系统对比实验，获得了丰富的实证经验。特别是在机器学习策略中，深刻认识到金融市场预测的困难性——AUC接近0.5并不意味着策略无效，关键在于如何利用模型输出构建有正期望的交易规则。这一认知对于理性看待量化交易的预期收益具有重要指导意义。

（二）未来展望

基于本研究的经验和发现，未来计划在以下方向进行深入探索。

第一，因子工程深化。当前策略仅使用技术指标因子，信息维度单一。未来将引入基本面因子（如估值、成长性、盈利质量）和另类数据因子（如新闻情感、资金流向），构建多维度因子库，提升模型的预测能力。

第二，深度学习模型探索。尝试使用长短期记忆网络（LSTM）和注意力机制（Attention）处理时序数据，利用其更强的序列建模能力捕捉价格运动的中长期模式。同时探索强化学习在动态仓位管理中的应用。

第三，多策略组合优化。将双均线、海龟和机器学习策略按风险预算模型进行配置，研究不同策略之间的相关性结构，通过优化权重分配实现组合层面的风险收益最优化。

第四，实盘交易验证。在模拟验证的基础上，选择表现稳健的策略进行小资金实盘测试，重点关注交易成本、滑点和冲击成本对策略表现的实际影响，不断完善策略的工程化实现。

量化交易是一个持续学习和迭代的过程。本报告所呈现的成果仅为阶段性总结，未来将在因子挖掘、模型创新和组合管理方面不断深化，追求更加稳健和可持续的投资回报。

附录：改进建议

建议1：双均线策略增加过滤条件

双均线策略在中船特气上收益突出但回撤较大（27.96%），建议增加成交量或波动率过滤条件——仅在成交量放大或波动率收缩时执行金叉信号，以减少震荡市场中的虚假信号，降低无效交易次数。

建议2：海龟策略引入多周期确认

海龟策略的唐奇安通道突破信号在震荡市中容易产生假突破。建议引入多周期确认机制——短期通道突破需得到长期趋势方向的支撑，即仅在长期均线向上时执行买入信号，避免逆势交易。

建议3：构建策略权重动态调整机制

多策略组合的静态等权配置未充分利用各策略的时变表现差异。建议基于各策略近期的夏普比率或胜率动态调整权重，增加表现稳定策略的配置比例，降低回撤期策略的暴露。

建议4：丰富机器学习因子维度

当前技术指标因子的AUC接近0.5，预测能力有限。建议引入基本面因子（市盈率、市净率、净资产收益率）和情绪因子（龙虎榜数据、融资融券余额变化），从多维度刻画股票的涨跌驱动力。

建议5：采用滚动窗口训练框架

一次性训练的模型无法适应市场环境的变化。建议采用滚动窗口训练——每月或每季度使用最近N个月的数据重新训练模型，使模型始终适应当前的市场状态，提升样本外的泛化能力。

建议6：纳入交易成本和滑点模拟

当前回测未充分考虑交易成本的影响，可能高估策略收益。建议在回测中纳入佣金（万分之三）、印花税（千分之一）和滑点（0.1%至0.2%）的模拟，使回测结果更接近实盘表现。